啤酒风味建模论文审查与实验改进方案

审查摘要

针对MathorCup 2026赛道A最新原始评分完善稿，核查论文、赛题、方法实现和现有实验。优先处理累计分布距离与标准RPS的区别、图模型单折与聚合评价方向不同，以及严格浓度约束与阈值风险约束的适用范围。针对预测增量、非零等级识别、缺失机制、化学异常、因素稳定性、生成覆盖和不确定性提出11项可执行实验，明确对照、指标和完成标准。方法新颖性以任务适配、风险可行域诊断和独立评价设计为主。本报告是后续研究方案，原论文未修改。

审查重点：评价口径；阈值约束；强基线；稳定性；生成验证；写作精简

目 录

1 总体评价与处理优先级 1

2 两处应优先修正的评价与推理问题 2

3 迁移约束：从无解结果到可解释的方法 3

4 第一问：强基线、非零等级与增量信息 4

5 缺失鲁棒性与化学尺度敏感性 5

6 第二问：关键因素的选择不确定性与网络作用 6

7 第三问：生成质量与迁移效果的独立评价 7

8 区间、评分人员与泛化范围 8

9 新颖性定位与写作改进办法 9

10 实施清单与完成标准 10

附录A 证据位置与参考文献 11

1 总体评价与处理优先级

审查对象为 paper/revised_absolute_20261025/论文完善稿.md 及配套PDF、原始A题、第三和第四阶段代码与结果。本文提供问题诊断、解决办法及待开展实验，不改写论文。审查日期为2026年10月28日。

总体判断：数据来源核查、按酒划分和训练内预处理已有较完整基础；论文的主要短板是评价口径不一致、部分结论超出了比较结果，以及迁移约束比题意采用了更强的解释。现有工作以成熟方法的任务适配和组合为主，算法原创性有限。最有价值的后续方向是解释约束如何决定迁移可行域，并验证化合物信息在风格信息之外的增量。

优先级	具体问题	应形成的成果
P0	累计分布距离被称为标准RPS；图结论遗漏聚合口径	指标定义与双口径比较表
P0	浓度逐项不增加与超阈值风险不增加混用	两类可行域、阈值敏感性和不可行证书
P1	强基线不足；非零等级表现弱	中位数与风格基线、分层等级指标
P1	缺失实验仅覆盖随机掩码	浓度依赖、检测通道缺失及处理对照
P1	Top-3稳定性以固定全数据参数为条件	完整选择流程重采样与模块证据
P1	风格识别率高与生成覆盖度混为一谈	等样本量的保真度、覆盖度、重复率
P2	平均区间覆盖掩盖分组差异	逐属性、面板人数和风格覆盖表
P2	多处自我辩护重复出现	集中陈述边界、结果直接量化

建议先处理前三项数值与定义问题，再设计额外模型。复杂度增加只有在预先指定指标上产生稳定且有实际意义的收益，才应进入主方案。P0可主要通过现有输出核查完成；P1包含后续需要训练或重新抽样的实验。

2 两处应优先修正的评价与推理问题

2.1 原稿RPS实际为分布距离

证据：src/stage4_models.py 的 ordinal_summary 计算预测累计概率P与面板经验累计概率Q的平方差，再对六个边界平均。原稿公式（5）采用同一定义。记$D=(1/6)\Sigma(P_k-Q_k)^2$，它衡量两个分布的距离。针对个人实际等级Y的标准RPS使用事件I(Y≤k)，二者关系为$E[RPS(P,Y)|Q]=D+(1/6)\Sigma Q_k(1-Q_k)$。后项是面板内部评分分歧。

同理，原代码的Brier是$\Sigma(p_k-q_k)^2$；个人等级的期望Brier还要加上$1-\Sigma q_k^2$。固定同一批观测时，加回这些常数不会改变模型排序，但会改变指标绝对值和相对改善比例。该区分依据严格适当评分规则的定义[3]。

解决办法：保留原数值并更名为“累计分布平方距离D”，另报个人等级期望RPS；Brier同时区分分布距离和个人评分。用枚举七个等级的加权分数核验恒等式，不需要重训模型。

已核实实例：核心30项频率ET的D为0.021784，面板分歧项为0.088658，个人期望RPS为0.110442；总体分布基线的个人期望RPS为0.116855。因此D下降约22.74%，个人期望RPS下降约5.49%。两种比例应分别标明。

2.2 “真实图没有收益”缺少评价口径

核心30项	无图	真实图	真实图减无图
15折MAE的均值	0.536911	0.537035	+0.000124
每酒五次预测平均后的MAE	0.526148	0.524865	-0.001283

先平均预测再取绝对误差，与先算各折误差再平均是两个评价对象。已有 paired_graph_vs_none.json 也保留了聚合预测的负差值，原稿只讨论单折表，因而遗漏了这一结果。全数据最终$\lambda=0$说明最终Top-3来自岭回归，不能据此抹去其他划分中的图模型收益。

解决办法：主表同时给出单次拟合与重复拟合集成的误差，固定一个作为主要评价对象。准确结论是“真实图在单折平均口径下略差，聚合预测下有约0.0013分的小幅改善”。固定OOF的配对重采样仅反映已得到预测的条件不确定性；训练重拟合、调参和研究过程中的模型选择另需评估[4]。

3 迁移约束：从无解结果到可解释的方法

3.1 当前严格约束与赛题阈值措辞需要分开

赛题将缺陷与DMS、双乙酰、4VG、trans-2-nonenal、Stale hops等超阈值项联系起来。当前浓度混配要求所有四项化学浓度均不增加，这是更严格的建模选择。例如阈值19 μg/L、源浓度5 μg/L、候选10 μg/L时，严格约束拒绝候选，而二者的阈值超额均为0。

建议并列定义两种协议。严格协议A：c′_d≤c_d。风险协议B：R_d(c′_d)≤R_d(c_d)，其中R_d(c)=max(c/t_d-1,0)，等价于c′_d≤max(c_d,t_d)。B是对题面阈值措辞的一种可检验操作化，阈值的来源、单位和基质必须单独核验。Stale hops继续作为感官终点。

原先“混配无解”仅针对协议A。指令收窄前的补充计算发现，在同样55条来源/划分记录中，仅考察四项化学约束时，协议B在参考阈值的0.5、1、2倍下分别有15、30、34条允许正的Tripel混合份额。该结果尚未检查风格提升及Stale hops条件，应作为后续实验的动机。

3.2 实验E1：约束消融与不可行证书

固定G/J/T角色和Tripel锚点，分别求协议A、协议B的最大目标混合份额；对A逐次删除一项约束，记录可行记录数、最大份额及被放松缺陷的增加量。最终有效候选须再通过锁定后的J风格与Stale hops检查。删除约束只用于诊断，不作为最终合格条件。

设D的第a列为锚点与源酒的四项浓度差，混配要求Dw≤0、w≥0。各行按正尺度归一化得到D_norm；若存在v≥0，使每个锚点满足(D_normˆTv)_a>0，则任意w≠0都有vˆTD_normw>0，与Dw≤0矛盾。这给出零混合份额为唯一可行解的证书。可通过Σv=1并最大化最小余量的线性规划求取。行缩放避免不同浓度单位主导数值求解。

已获得的证据：55条协议A记录均存在正余量证书；39条可由单项约束阻塞解释，16条需要联合约束。删除DMS、双乙酰、4VG、nonenal后，分别有30、4、0、4条允许正份额。该诊断可把笼统的“无解”转化为具体的工艺瓶颈。

验收标准：输出每条记录的源酒、锚点、单位、约束余量、证书权重和最大份额；数值证书在独立计算中满足非负性及正余量。协议B候选另报阈值敏感性与J支持率，分母同时列记录数和独立源酒数。

4 第一问：强基线、非零等级与增量信息

4.1 实验E2：化合物相对风格信息的增量

问题：原稿主要用总体均值作MAE基线。绝对误差下的最优常数是中位数；不同风格已有明显感官差异，也应提供风格基线。补充结果中，训练总体中位数的核心MAE为0.58785，风格中位数为0.50969，固定融合为0.50222。固定OOF下，融合减风格中位数的差为-0.00747，条件95%区间为[-0.01914,0.00418]。因此“相对均值降低16.92%”不足以说明化合物带来很大的额外增益。

实验设计：保持同一外层三折、五次重复，比较总体中位数、风格中位数、仅化合物模型、风格加化合物残差模型。残差模型先用训练折估计风格中心，再预测偏离中心的部分；风格中心、超参数和插补全部在训练折内确定。风格未知时只比较不使用风格的可部署方案，风格基线用于诊断信息来源。

指标：每酒五次预测平均后的核心MAE为主要指标，全50项MAE、各风格MAE和逐维误差为补充。以酒为配对单位，按风格分层重采样；报告条件差值区间，并将重拟合稳定性单列。建议预先设置0.01分作为内部实用改进门槛，或由队伍另行确定，不赋予其感官阈值含义。

4.2 实验E3：直接针对有序分布与零等级建模

问题：核心维度实测众数为0的比例为78.03%。原频率ET整体众数一致率为80.52%，非零众数一致率仅24.33%；新增风格分布基线的非零一致率为26.58%。总体命中率主要由零等级贡献。

先固定输出对象：个人评分的最可能等级、最小绝对损失等级和面板均分分别对应众数、中位数和连续均分。它们应分列交付，不能用面板众数一致率代表个人评分命中率。主要任务仍覆盖实际存在的全部50个目标，同时单报A/F核心30项。

候选方法一：用同一多输出树学习六个累计概率，再差分恢复七级概率。共享叶内权重保持累计概率单调，且训练平方损失对齐D。方法二：两段模型分别估计p0和条件于非零的1至6级分布，再按p_k=(1-p0)r_k组合。不要直接以测试集选择零等级阈值。

对照：总体分布、风格分布、原频率ET、累计概率ET、两段模型。除D和个人期望RPS外，报告逐目标混淆矩阵、非零等级误差、预测与实际零比例，并对p0作可靠性分箱图；校准方法仅以内层验证选择。

已有先导：累计概率ET的核心D从0.021784降至0.021703，差值区间[-0.000169,0.000004]包含零，非零一致率为24.88%。目前适合作为对照，证据不足以将其列为主要性能创新。两段模型尚未实施。

5 缺失鲁棒性与化学尺度敏感性

5.1 实验E4：让缺失机制接近测量过程

问题：现有0%、5%、10%、20%额外缺失采用MCAR随机掩码，只回答随机丢失输入时的表现。低浓度低于检测限、某类检测通道失效、某批样本整体缺测，具有不同的错误结构。

设计四组测试：①保留现有MCAR；②依赖已观察风格或其他测量值的MAR掩码；③优先掩去本变量低浓度值的MNAR掩码；④按检测来源或化学模块整块缺失。每种机制采用5%、10%、20%的目标缺失预算，实际实现的比例单独报告。只在外层测试输入上施加掩码，并保持各方法使用同一掩码。

处理对照：训练中位数插补、训练中位数加缺失指示、训练内拟合的多变量插补。缺失指示若在训练中缺少变化，可在训练折加入同机制增强；增强与不增强分开比较，所有参数在训练折内固定。新产生的测试缺失不得用于更新中位数或插补器。

指标：ΔMAE、ΔD、等级变化率、非零识别变化，以及五个缺陷终点的单独误差。报告总体与最差风格结果；测试中的缺失值若来自已知原值，可另外评价插补误差。检测限未知时，低值遮蔽只称为机制敏感性，不将其视为实际LOD。

5.2 实验E5：80处化学差异是否影响关键结论

问题：审计识别了32列、80处数值例外，但“保留异常”尚未量化这些例外对预测、Top-3和迁移的影响。原稿又有61浓度字段模型，具备直接进行敏感性对照的基础。

固定逐项异常清单，比较三个数据版本：V0保留原附件；V1仅将已识别不一致项设为缺失并在训练内处理；V2只采用单位、映射和数值来源均可追踪的字段。不得依据测试误差删除异常点或选择数据版本。对数、原始浓度和零替代的变换分别登记。

比较内容：同划分预测差、Top-3 Jaccard、入选频率变化、迁移可行数及阻塞约束变化。若主要结论只在某个异常处理版本成立，应将适用条件写到该结论旁；若一致，则可以用敏感性结果支撑稳定性。

优先核查nonenal的mg/L单位及其大OAV尾部、DMS和4VG的零替代、五个综合量与组分的关系。只在公式已核实的综合量上重算；其余作为独立测量字段处理或在受约束生成中排除。

6 第二问：关键因素的选择不确定性与网络作用

6.1 实验E6：重采样必须包括参数选择

问题：目前200次bootstrap重建预处理和图，但固定全数据选择的参数，因此频率只度量条件稳定性。150条Top-3中36条通过描述性支持条件，独立普通岭实现换种子后为37条，显示硬阈值附近结果会波动。应保留频率与贡献的连续数值，而非仅用通过/不通过。

完整选择重采样：以酒为单位、按风格分层bootstrap 200次；每次重新预处理、内层选α/λ/τ、重建图并选Top-3。一次被抽中的酒的所有复制必须分配到同一内层折，以免复制样本泄漏。将该频率与现有固定参数频率并列，同时报告每次λ=0的比例、排名分布和跨方法Jaccard。

无信号参照：在风格内整体打乱每款酒的50维感官向量，再运行相同选择流程，形成保留目标间结构与风格差异的经验参照。若进一步报告p值或显著性筛选，应预先定义检验族，并控制多重比较。原有“频率≥0.5”等条件继续称描述性规则。

6.2 实验E7：以模块效应解释共线化合物

问题：相关化合物可相互替代，单变量置换会离开原有联合分布，排名也可能随重采样变化。相似的整体预测误差不能说明每个Top-3具有稳定、独立的贡献。

方案：保留已有风格内置换、模块联合置换与删除模块重拟合，明确模块只由训练折建立。对同一模块中的可替代变量，增加训练内条件预测残差的置换敏感性；比较其方向、幅度与普通置换。化学解释优先落在得到稳定支持的模块，再讨论具体化合物。

交付表每行包含：目标、化合物及单位、完整选择频率、系数方向、普通/风格内/模块贡献、跨方法重叠、文献证据和测量条件。文献中的同类气味只能支撑合理性，具体作用仍需目标与剂量相匹配的证据。

6.3 补足图模型的数学论证

对对称权重W，L=diag(Σ|W|)-W满足 bˆTLb=Σ_{i<j}|W_ij|(b_i-sign(W_ij)b_j)^2≥0。因此α>0时，ZˆTZ+αI+λL在λ≥0下正定，优化问题具有唯一解。正文应给出这一推导，并说明负边约束的是系数反向关系。图正则化属于既有方法[5]，本题贡献需由消融和解释结果体现。

网络预测增益很小时，可将其定位为共变化结构与模块解释工具。最终λ=0的Top-3应明确归属于岭回归。

7 第三问：生成质量与迁移效果的独立评价

7.1 实验E8：区分逼真、覆盖与复制

证据：Tripel的受约束局部凸组合在J分类器中的目标识别率为69.5%，高于重采样的56.5%；其MMD平方为0.1158，却高于重采样的0.1034。分类器更容易识别，不等于更接近完整的真实风格分布。局部凸组合易集中在典型区域，稀有风味可能覆盖不足。

保持风格内重采样、局部凸组合、PCA高斯和受约束凸组合四组。各组使用相同的生成数量，并让所有方法重复抽取与真实留出相同数量的生成点作MMD/能量距离比较。训练表示与核带宽固定于G，报告稀有风格每次真实留出的实际数量。现有MMD使用含对角项的V统计量，有限样本偏差也应说明。

同时评价：①生成点到训练点最近距离和精确重复率；②真实留出到生成集最近距离，反映覆盖；③生成集内部距离和有效秩，检查收缩；④边际分位数与相关结构偏差；⑤J目标风格识别率。以保真度和覆盖度共同决定方法，不按单一分类概率选胜者。

验收：若识别率提高而覆盖和相关结构变差，应报告取舍；只有在预先指定的距离、覆盖和复制约束均满足时，才称生成质量整体改善。多次划分中的同一酒不计作新增独立样本。

7.2 实验E9：迁移先锁候选，再检验代理一致性

问题：当前T来源10条迁移记录涉及7款不同酒，加入原始评分条件后仅1条获全部代理支持。应区分搜索可行、独立代理认可、浓度约束可行和实物品评四个终点。

执行顺序：在G中完成搜索和排序，保存候选哈希；J只做一次预先规定的复核；T评价原预测器在真实酒上的识别与感官误差。新增协议B候选也遵循同一流程。若查看J后改变搜索规则，应另列开发版本，并使用重新封存的数据或后续新样本评价。

代理稳健性：将训练样本与模型家族的变化作为单独因素，比较线性与树模型对同一候选的风格增益、Stale hops差及预测区间。对稀有风格先报告真实留出识别能力；能力不足时，高目标概率的含义有限。

最终表同时报告全部来源、每个半径的失败数、独立源酒数、J一致支持数、四化学风险及Stale hops变化。统计空间允许的特征变化若缺少制备路径，应继续作为风味指纹候选；要称为配方，还需原料比例、工艺和测量闭环。

8 区间、评分人员与泛化范围

8.1 实验E10：逐目标与分组覆盖诊断

问题：原稿五次分割的平均覆盖率为90.06%，容易使读者忽略特定目标的欠覆盖。已有结果中，barnyard平均覆盖为84.0%，F_malt_all为84.8%，Stale hops为85.2%。这些是重复划分的描述性比例；同一酒重复出现，不能据250条测试记录套独立二项区间。

先对现有区间按目标、不同评分人数及风格分组，列出独立酒数、覆盖率与宽度。重复酒按酒聚类报告不确定性。小组样本太少时展示计数和逐次结果，避免宣称稳定的条件覆盖保证。

后续方法：在训练数据内拟合残差尺度σ(x)，用校准分数|y-f(x)|/σ(x)构造归一化保形区间。σ须在校准之外训练；可用化学特征与已知风格，若使用未来预测时未知的面板人数，则另列条件场景。与原等宽区间比较覆盖、平均宽度和最差组表现。所有50维同时覆盖若确有需要，另用最大标准化残差校准并接受更宽区间。

8.2 实验E11：区分新酒预测与新人员泛化

已知原始评分来自16名人员，每款酒有3至14名不同人员，另有同人同酒重复。按酒划分可以评价同一历史品评体系下的新酒预测；训练与测试共享评分人员，使结论范围主要落在该体系。

建议先按目标拟合评分人员与啤酒的交叉效应，量化人员偏移、酒间差异和重复噪声。若部署对象是新面板，再另设人员留出：用剩余人员构造训练端点，在外层测试酒上用被留出人员评分评价；同时分离酒留出与人留出的影响。16人的样本量决定了结论需报告宽区间。

不要用模型残差直接替代人员分歧，也不要将平均人员bootstrap区间宽1.287分当作可达到的最低MAE；两者对应不同统计量。多属性、多人员和多批次中的相关性应在估计和重采样时保留。

8.3 实物验证的最小可执行设计

待化学约束和制备路径明确后，安排源酒与候选的随机编码配对盲评，保留批号、顺序和实际评分。三批次先在人内汇总或采用人员与批次交叉效应，30人三批次仍是30个独立人员单位。

原方案0.5分非劣界评价的是“允许幅度内不劣”，与严格差值≤0对应不同目标。该界应由感官重要性或预实验确定。若五个缺陷全部通过才声明整体非劣，这是交并检验结构；各终点可使用整体显著性水平α；逐项α=0.01属于更保守的预设。单终点功效应与五终点共同通过概率分别规划。

9 新颖性定位与写作改进办法

9.1 新颖性评价

原始研究已经在250款啤酒上进行化学与感官建模、比较多种机器学习方法，并通过加标实验验证部分预测[1]；公开仓库也包含ET、梯度提升等模型和原始面板数据[2]。因此“使用机器学习预测啤酒风味”“用树模型发现关键化合物”本身难以构成本文新颖性。

方向	当前性质	形成贡献所需证据
原始评分身份与尺度重建	数据整合与可复现性贡献	映射规则、属性分组核查、异常记录
ET/GBR融合、图回归、保形区间	成熟方法的任务适配	同划分基线、消融、增量与不确定性
累计概率或两段等级建模	有序/零膨胀思想的应用	非零等级与适当评分的稳定提升
阈值风险可行域与不可行证书	值得深化的任务方法贡献	A/B协议、联合阻塞证明、约束消融
冻结候选、多模型独立复核	评价设计贡献	锁定记录、独立角色、稳定失败模式

建议主线：“在来源可追踪的0-6端点上，将预测、因素稳定性与缺陷风险约束连接起来，用可行证书和独立代理解释迁移成败。”如果后续实验证实阈值协议和不确定性处理能改变可行候选集合，这一主线比继续增加复杂算法更有辨识度。新颖性判断限于本次核查的原始研究和相关方法，首次性仍需专门检索。

9.2 减少防御性写作的具体处理

原文类型	建议处理
“未冒充已完成”“不把失败掩盖成成功”	删除；实物验证状态集中写一次。
“不主张发明新的基础算法”	直接列已有方法与本文新增的组合、诊断及证据。
“不能证明所有网络方法在所有数据上都无用”	删除；改为本数据、本参数范围和具体误差差值。
“不能把约80%一致率称为强的精细分级能力”	直接列总体一致率80.52%、非零24.33%及零占比78.03%。
“不是新酒实测”“不是外部验证”反复出现	在数据范围及结果表注集中说明观测来源和验证对象。
“可能与多种原因有关”但无证据	列已知异常、待核验因素和可区分原因的实验。

保留会改变结论的条件：未知LOD、化学单位未核实、条件bootstrap不含重训、人员与酒样的泛化范围、阈值的基质依赖。每句只承担事实、解释、论据或必要边界中的至少一项；纯立场表态和预防性辩护删除。

10 实施清单与完成标准

顺序	任务	最小交付	状态
1	RPS/Brier定义、图双口径	修正公式和比较表	问题与数值已核查；正文待队伍处理
2	E1：严格/阈值协议	证书、约束消融、阈值表	化学可行性先导已产生；J复核待做
3	E2/E3：强基线与等级	共享划分、逐维成绩、校准图	基线与CDF先导已产生；其他待做
4	E4/E5：缺失与化学异常	固定异常清单、机制×方法表	待设计确认与执行
5	E6/E7：因素与模块	完整流程频率、模块贡献表	待补充完整选择重采样
6	E8/E9：生成与迁移	等样本量距离、覆盖、锁定候选	待补充
7	E10/E11：覆盖与人员	分组区间表、人员影响估计	分组问题已核查；扩展待做

统一实验约定：在执行前固定主要指标、数据划分、超参数候选、缺失掩码生成规则、接受门槛和停止条件；原有外层划分用于可比的内部研究，不因更换种子自动获得新的独立验证。新的方法选择仍应限制在内层，最终对未来或封存的新数据检验泛化。

每个实验保留配置、角色表、输入哈希、逐酒预测、逐目标指标和失败记录。50个目标与同酒重复结果作为关联观测处理；统计单位依问题采用酒、人员或独立批次。计算性质测试用于核对实现，研究结论仍由对应的数据与比较支撑。

本轮范围说明：用户将任务收窄为“找问题、设计实验、提供解决办法”前，已执行一轮累计概率ET与基线对照、固定OOF重采样、混配证书和阈值可行性诊断，相关数值在本报告中明确标为已有先导。此后仅编写审查报告；原论文Markdown、PDF及其生成脚本均未修改。上述先导输出保留在本地 outputs/review_20261028，后续训练任务未启动。本次GitHub交付仅包含审查报告及其可编辑来源。

AI辅助范围：来源核查、代码与输出审阅、上述先导计算、实验方案和报告整理。未来实物测量、人员评分、团队独立复核及方案执行状态由实际记录补充。

附录A 证据位置与参考文献

问题	仓库内证据位置
最新论文	paper/revised_absolute_20261025/论文完善稿.md；paper_content.json
RPS/Brier实现	src/stage4_models.py：ordinal_summary；outputs/stage4/ordinal/metrics_by_scope.csv
预测与区间	outputs/stage4/prediction/metrics_by_scope.csv；conformal_coverage.csv
图两种评价口径	outputs/stage4/raw_graph/q2/graph_comparison.csv；paired_graph_vs_none.json；oof_graph_real.csv；oof_graph_none.csv
因素与稳定性	src/stage3_graph.py；outputs/stage4/raw_graph/q2/top3_with_evidence.csv
生成与迁移	src/stage3_generation.py；outputs/stage3/q3/generation_summary.csv；outputs/stage4/transfer/
本地先导记录	outputs/review_20261028/ordinal_metrics.csv；paired_comparisons.csv；mixture_certificates.csv；threshold_excess_sensitivity.csv；run_manifest.json

参考文献与核查日期：2026年10月28日。原始论文用于方法与贡献定位；新版数据页面用于核查数据版本与文件来源；其余文献支撑指标及统计方法定义。

[1] Schreurs M, et al. Predicting and improving complex beer flavor through machine learning. Nature Communications, 15:2368, 2024. DOI:10.1038/s41467-024-46346-0. https://www.nature.com/articles/s41467-024-46346-0

[2] Schreurs M, et al. Data from: Predicting and improving complex beer flavor through machine learning. Zenodo, v4, 2026-10-24. DOI:10.5281/zenodo.23624915. https://zenodo.org/records/23624915

[3] Gneiting T, Raftery A E. Strictly Proper Scoring Rules, Prediction, and Estimation. Journal of the American Statistical Association, 102(477):359-378, 2007. DOI:10.1198/016214506000001437. https://sites.stat.washington.edu/people/raftery/Research/PDF/Gneiting2007jasa.pdf

[4] Bengio Y, Grandvalet Y. No Unbiased Estimator of the Variance of K-Fold Cross-Validation. Journal of Machine Learning Research, 5:1089-1105, 2004. https://www.jmlr.org/papers/v5/grandvalet04a.html

[5] Li C, Li H. Variable selection and regression analysis for graph-structured covariates with an application to genomics. The Annals of Applied Statistics, 4(3):1498-1516, 2010. DOI:10.1214/10-AOAS332. https://pmc.ncbi.nlm.nih.gov/articles/PMC3423227/