基于尺度审计与稳定关联的啤酒感官预测及风格约束迁移

摘 要

针对啤酒化合物到感官画像的预测、关键因素分析和风格生成问题，构建数据审计、多输出预测、网络关联解释及约束迁移的统一研究流程。依据实际附件，以 beer 为唯一键关联 250 个样本、231 个数值字段和 50 个连续感官目标，逐列核查对数尺度与缺失处理。原始研究采用按品评人员标准化的评分，缺少原始参数时绝对 0—6 分不可唯一恢复，故将连续预测与分级假设分开验证。在训练折内预处理和调参的三折两次重复验证中，固定配置 GBR 的宏平均 MAE 为 0.3398，相对均值参照下降 18.51%；独立训练、校准和测试分割下，名义 90% 的逐维边际区间获得 92.28% 的平均测试覆盖率。三类分级假设在 84.48% 的预测位置存在分歧。第二问以相关网络和图约束岭回归产生 Top-3 候选，结合 bootstrap 与留出置换贡献，仅 11/150 条通过当前描述性证据条件。第三问比较重采样、局部凸组合和 PCA 高斯生成；局部凸组合保留非复制样本优势，但分布距离未全面优于重采样。扩展迁移搜索为 11 个源样本找到模型内可行候选，其中 2 个含缺失缺陷源值。结果支持相对感官预测与受约束的统计设计，尚不支持绝对评分恢复、化学因果或真实酿造效果的结论。

关键词：感官预测；数据尺度；图约束回归；重采样稳定性；条件生成；约束迁移

目 录

1 问题重述与研究范围 1

2 模型假设与符号说明 1

3 数据审计与预处理 2

4 第一问 感官预测与分级不确定性 3

5 第二问 化合物网络与解释证据 5

6 第三问 风格生成与约束迁移 7

7 稳健性 可复现性与模型评价 9

8 结论与建议 10

参考文献 10

AI 工具使用声明 11

附录 复现与结果索引 11

1 问题重述与研究范围

啤酒风味由原料、发酵过程和多种化合物相互作用共同形成。原始研究已将实测化学资料与训练品评联系起来，说明此类数据具有建模价值[1]。本题进一步要求处理缺失、分级评分、稳定因素识别和跨风格生成，因此研究重点不仅是拟合精度，还包括目标定义是否清楚、解释是否稳健，以及生成谱满足什么层次的约束。

第一问以化合物和理化测量为输入，估计品评表各感官维度；第二问建立化合物关系网络并对每维给出三个候选因素；第三问按 tasting_category_fine 生成风格条件样本，并将 Pils/Lager 向 Tripel 调整，要求指定缺陷项不恶化。本文对实际附件的 50 个连续目标完整输出，Aroma 与 Flavour 维度单独标识；最终提交维度应依据官方明确口径核对。

本文研究范围为对给定附件的统计建模与可复现验证。原始 0—6 分锚点、部分浓度尺度、聚合量公式和真实感官试验均存在信息缺口。对这些缺口采用明确假设、敏感性和失败记录处理，保留可核查结果，不以预测代理替代实测。

2 模型假设与符号说明

2.1 基本假设

假设一，beer 能稳定标识同一款啤酒，不同文件按该字段正确对应。该假设经唯一性、集合和风格一致性检查支持；受损的 beer_id 不用于合并。假设二，在相同数据获取机制下，现有样本可用于研究新样本的相对感官预测；此假设不保证未见风格或不同酿造工艺下的外推。

假设三，训练分布的分位截尾与中位数插补可作为噪声、极端值与缺失的研究基线。它们不证明被处理值是错误观测，后续需要针对检测限与非随机缺失改进。假设四，相关网络可作为参数正则化信息，但不具有先验因果含义。假设五，生成与迁移的经验范围和代理模型只定义统计可行性，不构成物理、化学或生产可行性的充分条件。

2.2 主要符号

符号	含义
n、p、q	样本数 250、输入字段数 231、感官目标数 50
X、Y	附件尺度输入矩阵与连续感官目标矩阵
Z	仅由训练数据拟合预处理得到的标准化输入
B、α、λ	回归系数、岭惩罚和网络惩罚强度
W、L	截断有符号相关权与对应拉普拉斯矩阵
f、g	连续感官预测器与风格诊断分类器
c、h	目标风格条件与低维潜变量
D、D_hat	缺陷化学字段集合与学习得到的感官缺陷代理

3 数据审计与预处理

3.1 样本与字段核查

实际附件中 1.csv 有 250 行、234 列，前 3 列为元信息，其余 231 列包括化合物、理化和综合字段；4.csv 含 50 个连续感官目标。化合物条码在感官文件中存在精度损失，直接用条码合并可能产生多对多错配。程序要求 beer 非空、唯一、两表集合相同，并在对齐后检查风格标签一致。

资料	实际结构	研究用途
1.csv	250×234，含 3 列元信息	化合物及理化输入
2.csv	去行名后 231×231	描述性相关网络
3.xlsx	12 个 beer 页及 summary	感官定义与空模板审计
4.csv	250×53，含 50 个目标	连续感官监督信息
6.csv	去行名后 44×50	跨域关联参考，不作新样本
8.xlsx	阈值、名称、校准等工作表	尺度和术语证据

完整原件以 SHA-256 绑定版本。字典、字段尺度、缺失统计和样本键检查随支撑文件保存。题面与文件的数量差异按实际证据记录，不补造缺失行列。8.xlsx 中已有 SHAP 与重要度属于既有研究结果，未作为本文重新训练得到的结论，也不用于第一问的外层变量筛选。

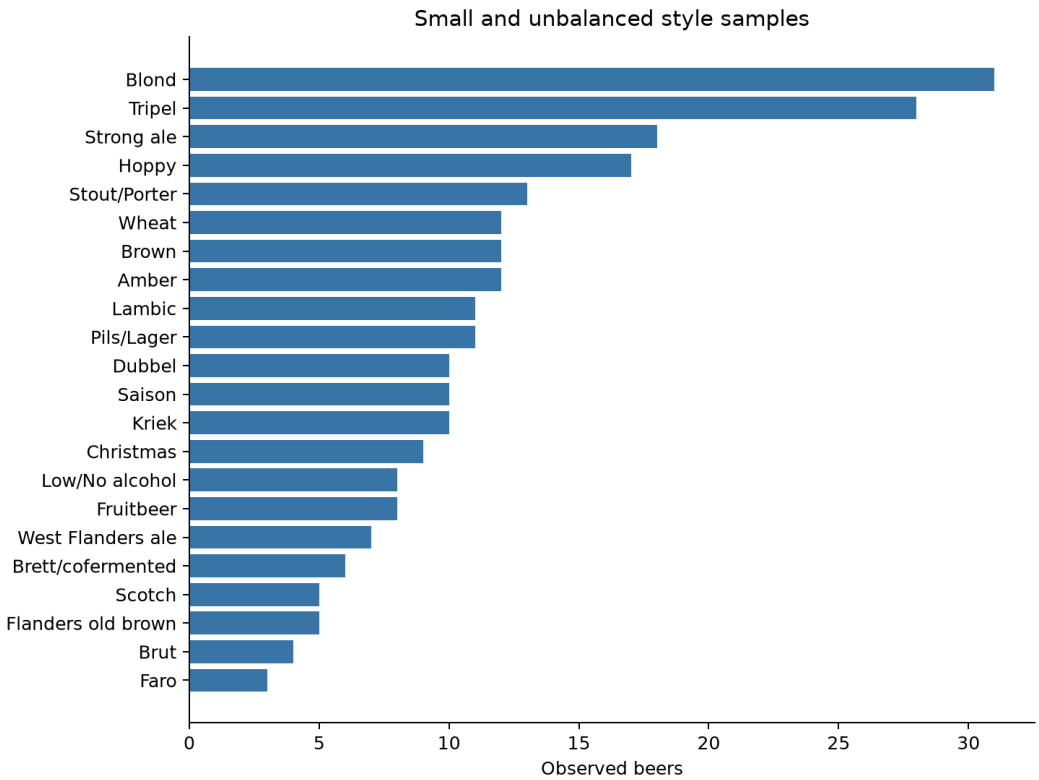


图1 风格样本数分布 显示小样本与类别不平衡

3.2 量纲与缺失处理

对可比的原始正值配对，逐字段比较恒等关系与 log10 关系。检查支持 37 个字段在这些配对上符合 log10，包括题面列为可能保留原量纲的部分理化指标；另有字段只在多数配对一致，或缺少可比原值。正值配对一致性并不能识别零替代值与检测限。故保留附件尺度建模，不对所有字段统一逆变换。

给定相关矩阵与重算 Spearman 的平均绝对差为 1.58323e-16，与 Pearson 为 0.0873039，更支持采用秩相关解释。矩阵的完整结构一致性也用于核对字段别名次序。自然缺失由训练中位数填补，训练 1% 和 99% 分位定义截尾范围，再作训练均值与标准差标准化。所有操作置于 Pipeline 中[2]。

$$z_{ij} = \frac{\mathrm{clip}(x_{ij}; a_j, b_j) - m_j}{s_j} \tag{1}$$

式（1）中的边界、插补值、均值和标准差均只在当前训练数据估计。验证与测试样本仅执行变换，不参与参数学习。对极端值的处理属于可检验的建模假设，而非原始观测纠错。

4 第一问 感官预测与分级不确定性

4.1 评分尺度的可识别性

原始研究明确说明按品评人员分别中心化和标准化，并非仅对汇总后的每个属性作一次统一线性变换[1]。设品评人员 t 的原始评分为 s_it，标准化后为 z_it，若其均值 μ_t 与标准差 σ_t 未知，则不能从 z_it 唯一得到 s_it；不同品评人员的出席与汇总权重进一步增加信息需求。

$$z_{it} = \frac{s_{it} - \mu_t}{\sigma_t}, \qquad s_{it} = \mu_t + \sigma_t z_{it} \tag{2}$$

对于缺少锚点的数据，多组满足原始评分范围的 μ_t、σ_t 都可能产生相同标准化值。空模板公式返回的零也不等于真实打分。因此本文把可验证的连续预测和有假设的相对分级分开，未把简单拉伸、裁剪或经验分位声称为原始评分恢复。

4.2 多输出预测模型与求解

设第 k 个感官目标的预测为 f_k(x)。比较训练均值、岭回归、PLS、ExtraTrees[3]、固定配置梯度提升回归[4]以及固定比例的岭回归与 ExtraTrees 融合。岭回归通过 L2 惩罚控制高维共线，PLS 学习与目标相关的低维方向，树模型捕捉非线性。输入中不包含编号、条码、风格标签或样本的感官评论信息。

$$\widehat{B} = \arg\min_{B} \left\{ \|Y_c - ZB\|_F^2 + \alpha \|B\|_F^2 \right\} \tag{3}$$

岭回归 α 在 {1,10,100,1000} 中由内层三折选择；PLS 成分数在 {3,8} 中选择。ExtraTrees 使用 200 棵树、最小叶样本 3、特征比例 0.8。GBR 对每个目标分别拟合 100 棵深度为 2 的树，学习率 0.04，最小叶样本 5，特征比例 0.7。GBR 参数为第二阶段固定探索配置，未根据本阶段外层目标逐折调整。

4.3 验证设计与性能

采用按风格分层的三折、两次重复外层验证。每个样本每次重复仅被留出一次，预处理和调参在外层训练数据内完成。重复留出预测取均值后计算逐维指标，并对 50 维等权宏平均。最少风格有 3 个样本，选用三折避免强行采用超过该样本数的分层折数。第二阶段是在第一阶段观察之后的探索改进，不能视为未接触过数据的外部验证。

$$\mathrm{MAE} = \frac{1}{nq}\sum_{i=1}^{n}\sum_{k=1}^{q}|y_{ik} - \hat{y}_{ik}| \tag{4}$$

方法	宏平均 MAE	宏平均 RMSE	宏平均 R^2
均值参照	0.4169	0.5687	-0.0067
岭回归	0.3554	0.4947	0.2030
PLS	0.3524	0.4857	0.2205
ExtraTrees	0.3416	0.4785	0.2397
固定 GBR	0.3398	0.4751	0.2432
固定比例融合	0.3451	0.4823	0.2336

GBR 的 MAE 为 0.3398，相对均值参照下降 18.51%。它与 ExtraTrees 的差距较小，不能仅据单个平均值断言普遍优越。宏平均 R^2 约 0.243，说明仍有较大未解释变异；逐维性能可能差别明显。上述单位均为附件的连续目标尺度，不能改写成 0—6 分的平均误差。

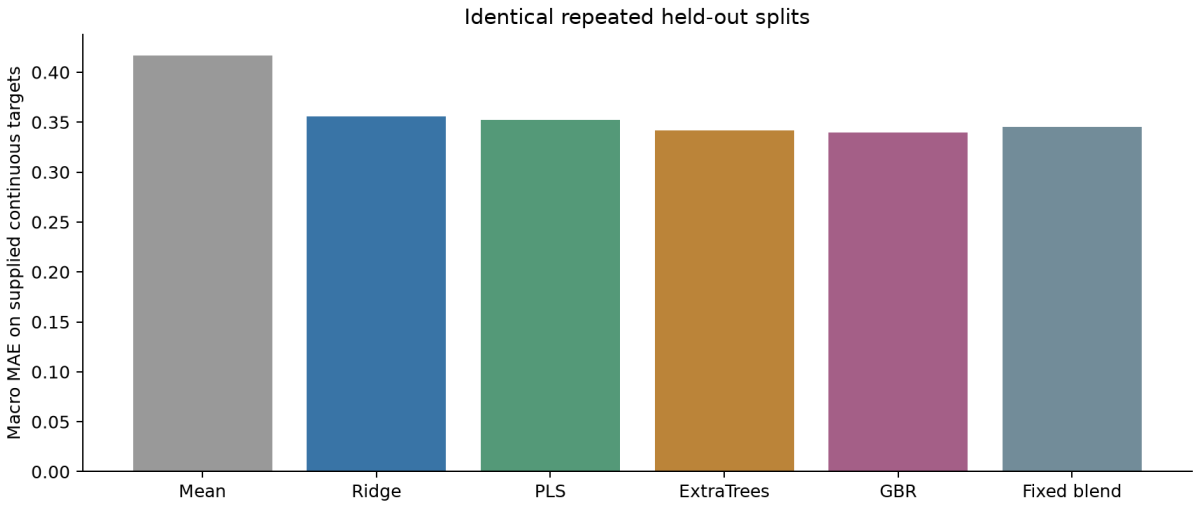


图2 六类方法在相同重复留出划分下的连续目标误差

4.4 分级敏感性与预测区间

在训练目标上分别构造七等频经验分位、正态分布累计概率和以 5%—95% 分位为端点的线性映射三类等级规则。它们均输出 0 至 6，但语义不同；重复分位边界也会影响离散分级。对每个外层留出预测比较三者，完整保存差异与跨规则范围。

三种规则在 84.48% 的预测位置给出不同等级，显示绝对标定对假设高度敏感。跨规则的最小值和最大值仅表示假设范围，不是统计置信区间。若获得参考酒原始评分或逐品评人员转换参数，

应重新标定和验证，再向原始 0—6 分作实质性解释。

另用 150 个训练、50 个校准、50 个测试样本展示分割保形预测[5]。用训练模型在校准集的绝对残差定义逐维分位，再为测试预测添加对称区间。名义水平为 90%，目标是单个感官维度的边际覆盖，并非所有 50 维同时覆盖。

$$r_{ik} = |y_{ik} - f_k(x_i)|, \quad r_k^* = r_{([(m+1)(1-\alpha)]),k} \tag{5}$$

$$C_k(x) = \left[f_k(x) - r_k^*,\ f_k(x) + r_k^*\right] \tag{6}$$

本次平均测试覆盖率为 92.28%，平均区间宽度为 1.6819。该结果只对应一次分割和当前连续标签；交换性假设、样本筛选与原作者预处理都会限制其外推。不能把边际覆盖率解释为每种风格或每款啤酒都达到同一保障，更不能据此推导原始等级的覆盖率。

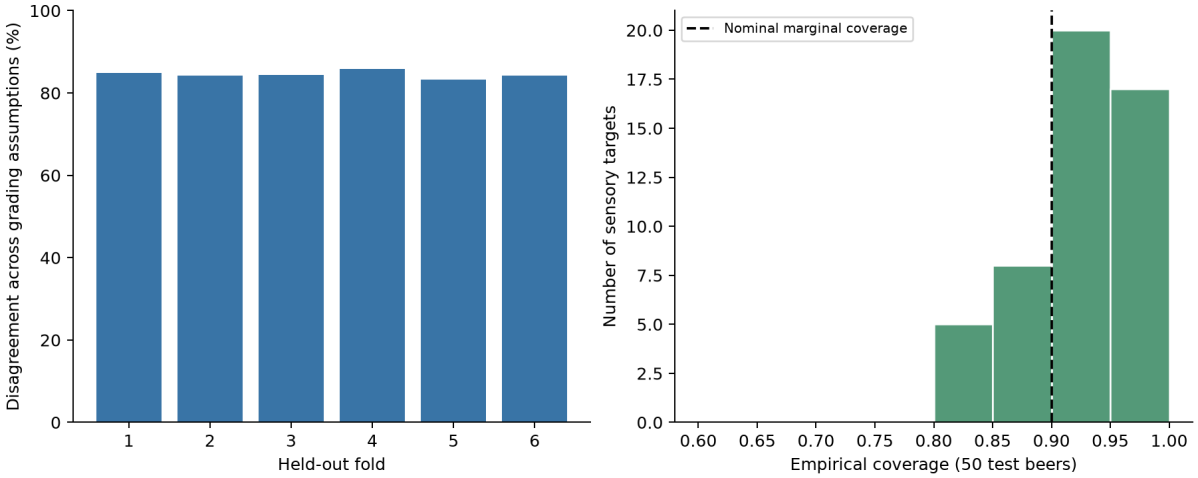


图3 分级规则分歧与逐维连续预测区间的测试覆盖分布

5 第二问 化合物网络与解释证据

5.1 共表达图及图约束回归

以 231 个数值字段为节点，给定相关矩阵中 $|r| \geq 0.7$ 时建立边，同时保存符号与绝对权重。当前有 109 条边；0.6、0.7、0.8、0.9 阈值的网络变化另存。模块包含孤立节点，不能直接当作生化通路。对每个目标最终只从化合物或元素字段中选择候选，pH、色度、混合和聚合指标不冒充单一化合物。

$$W_{ij} = r_{ij}\,\mathbf{1}(|r_{ij}| \geq \tau), \quad L = \operatorname{diag}\left(\sum_j |W_{ij}|\right) - W \tag{7}$$

$$\widehat{B} = \arg\min_B \left\{ \|Y_c - ZB\|_F^2 + \alpha\|B\|_F^2 + \lambda \operatorname{tr}(B^{\top} L B) \right\} \tag{8}$$

符号拉普拉斯的二次型为相关边上系数差异或相反关系的加权惩罚，矩阵为半正定。固定 $\alpha=20$、$\lambda=5$ 后，求解 $(Z^{\mathrm{T}}Z+\alpha I+\lambda L)B=Z^{\mathrm{T}}Y_c$。该模型提供一种利用关系结构的正则化基线，尚未证明固定参数最优。每个目标按标准化特征的系数绝对值取前三项，方向和相关性均保留。

5.2 重采样稳定性与留出置换贡献

采用 100 次样本有放回重采样，每次重新估计截尾、插补、标准化和秩相关网络，重新拟合并计数 Top-3。另比较图约束回归、无图岭回归和边际 Spearman 的名单 Jaccard。相关因素可能相互替代，所以单个因素频率低与模块关联存在并不矛盾。

$$\pi_{jk} = \frac{1}{R}\sum_{b=1}^{R} \mathbf{1}\left(j \in \mathrm{Top3}_k^{(b)}\right) \tag{9}$$

第二阶段对每个外层训练拟合的岭回归，在其留出样本上单独置换某一特征，观察逐维 MAE 增量，重复 5 次并汇总六个外层划分。对线性预测利用固定预处理后的变量差与系数精确计算，避免反复拟合同一模型。置换贡献取决于模型与相关结构，不是化合物的内在因果效应[6]。

$$\Delta_{jk} = \mathrm{MAE}_k\left(\widehat{Y}^{\mathrm{perm}(j)}\right) - \mathrm{MAE}_k\left(\widehat{Y}\right) \tag{10}$$

定义探索性证据条件：入选频率至少 0.5，平均留出 MAE 增量大于零，且至少三分之二外层划分增量为正。阈值为本研究的描述性判据，不是显著性检验或官方评分标准。由于候选名单包含全数据探索信息，筛选后的支持数仍存在选择适应性，不能作未经选择的独立假设检验。

150 条候选中，11 条同时满足当前条件。第一阶段有 137 条入选频率低于 0.5，说明多数 Top-3 还不适合写成确定因素。完整 150 条及所有变量的贡献保存在支撑表中，弱证据项和反直觉项不删除。

感官目标	候选字段	入选频率	留出 MAE 增量
A_malt_burn	methylpyrazine	0.69	0.00065
F_hops_all	ethyl_isovalerate	0.52	0.00439
F_esters_flower	styrene	0.51	0.00068
acidity	nonan.2.ol	0.71	0.00329
bitternes	iron	0.79	0.00725
X4vg	X4VG	0.99	0.01270
metallic	iron	0.88	0.00328
orange	X1.alpha.terpineol	0.81	0.00396
coriander	geraniol	0.62	0.00193
lactic	alpha.terpinyl.isobutanoate	0.57	0.00076
aftertaste	iron	0.63	0.00046

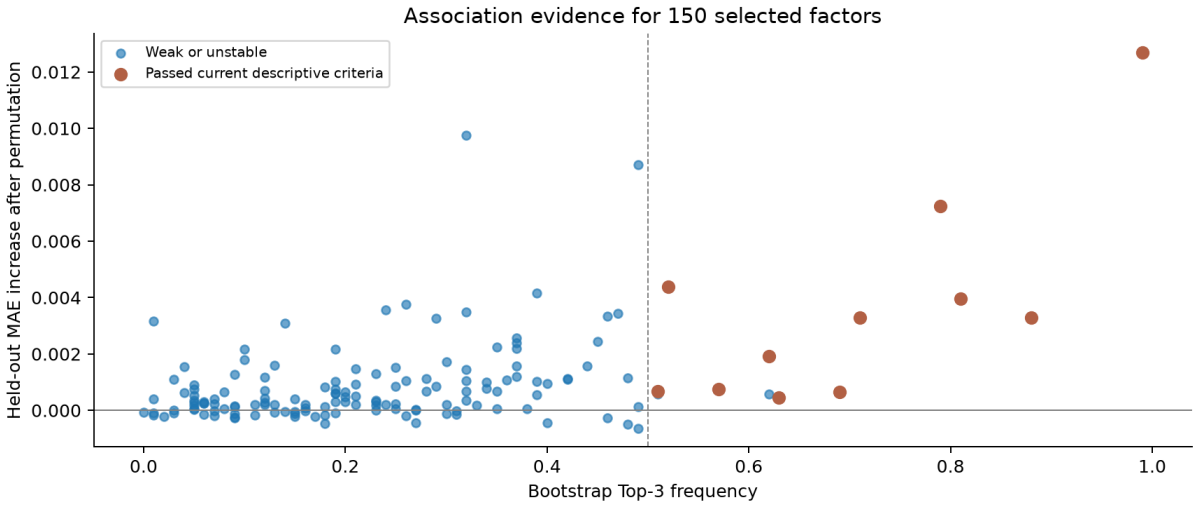


图4 Top-3 候选的重采样频率与留出置换贡献 通过描述条件仍不表示因果

5.3 化学合理性及反例

4VG 感官目标与 X4VG 的联系具有较强的统计一致性。原始化学研究指出 4VG 与特种啤酒的丁香气味相关，并研究了其陈化降解[7]，可作为该关联的外部合理性依据。金属味与 iron、烘烤麦芽与 methylpyrazine 等候选也可结合附件的名称、来源和缺陷描述继续论证，但本文未开展加标、盲评或反应机理实验。

表中也存在不宜直接解释为气味来源的关联，例如苦味与 iron、乳酸相关描述与某酯类字段。它们可能反映风格共变、共线替代或模型不足。源于同一附件的元数据只能提供术语与来源线索，不能独立验证每个目标的机制。对这些结果应保留待证状态，不能人为换成期望化合物来美化模型。

6 第三问 风格生成与约束迁移

6.1 小样本条件生成与对照

按风格分层留出 20% 样本，训练预处理和生成模型仅使用训练部分。比较三类方法：风格内 bootstrap、同风格近邻之间的局部凸组合，以及十维 PCA 中的条件高斯采样。PCA 模型以风格均值为中心，协方差按 n_c/(n_c+10) 将风格内估计与汇聚估计混合。

$$h \mid c \sim \mathcal{N}(\mu_c, w_c\Sigma_c + (1-w_c)\Sigma_{\text{pool}}), \quad w_c = \frac{n_c}{n_c+10} \tag{11}$$

局部凸组合在相同风格中选择一个训练样本和其近邻，以 0.1—0.9 的随机权重插值。该方法是一种条件经验生成模型，生成的新点不等同于化合物可直接混配的物理过程，尤其在对数尺度上只代表统计插值。

$$x_{\text{new}} = ux_a + (1-u)x_b, \quad u \sim \text{Uniform}(0.1, 0.9), \quad a, b \in c \tag{12}$$

6.2 生成验证与结果

用五种随机划分重复比较，每次为 Tripel、Kriek、Lambic 各生成 40 个谱。指标包括对真实非缺失留出测量的平均 KS、训练表示上的有偏 RBF MMD^2、目标风格分类概率及精确复制比例。分类器与生成器共享训练集，留出表现用于说明诊断模型能力；生成概率并不是外部独立风格鉴定。五次划分也会重复使用同一批酒。

风格	方法	平均 MMD^2	精确复制比例
Kriek	PCA_Gaussian	0.2638	0.00
Lambic	PCA_Gaussian	0.2716	0.00
Tripel	PCA_Gaussian	0.1397	0.00
Kriek	bootstrap	0.2295	1.00
Lambic	bootstrap	0.2666	1.00
Tripel	bootstrap	0.1071	1.00
Kriek	local_convex	0.2358	0.00
Lambic	local_convex	0.2671	0.00
Tripel	local_convex	0.1237	0.00

局部凸组合没有精确复制训练样本，目标风格分类概率较高；但其 MMD 未全面优于直接重采样。PCA 高斯的复杂性也没有带来分布距离优势。因每风格只有极少留出样本，尤其 Kriek 和 Lambic 每次通常只有两款，距离指标不能证明整个分布已被学会。生成模型的评价应同时看接近程度、复制风险与可解释约束，而不能只追求分类器高分。

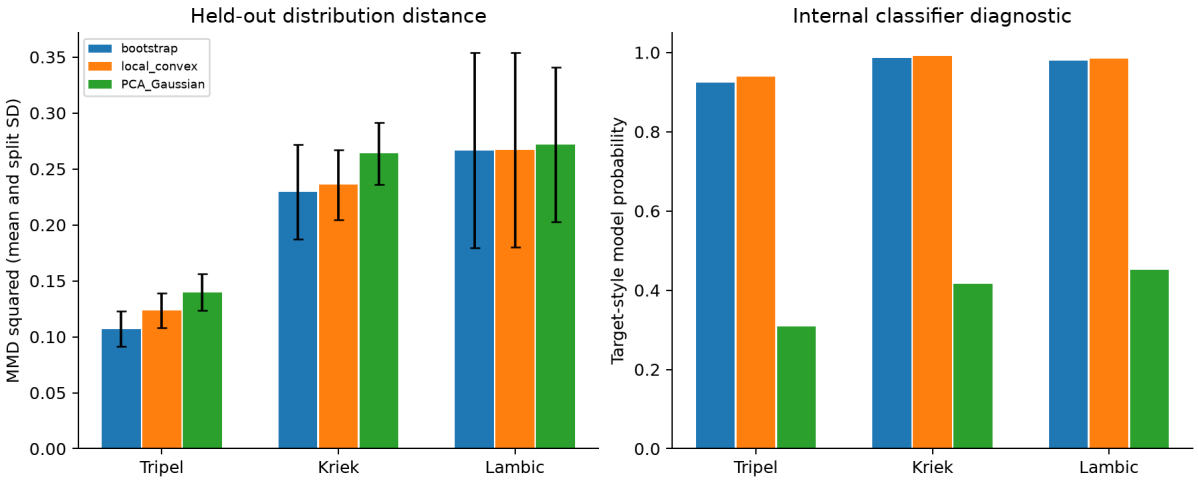


图5 五次划分下生成方法的分布距离与内部风格概率 误差线是划分标准差

第一种划分的局部凸组合样本及连续感官画像完整保存。画像来自第一问预先指定的全数据岭回归代理，因此不能用作独立的真实感官验证。五个综合指标随谱联合生成，原作者聚合公式尚未完整恢复，精确代数一致性也未被证明。

6.3 逐项缺陷约束与迁移搜索

第一阶段采用 PCA 风格均值方向搜索，11 个源样本中只有 7 个找到非平凡候选。第二阶段扩大为目标风格条件训练锚点搜索：对每个源样本，沿每个 Tripel 训练锚点方向取 30 个权重，再作经验范围投影与四项缺陷字段的逐项上界投影。四项分别为 DMS、双乙酰、4VG 和 trans-2-nonenal。相比单一潜方向，该搜索保留更多目标风格变化方向。

$$x_{\text{candidate},d} \le x_{\text{source},d}, \qquad \forall d \in D \tag{13}$$

$$f_{\text{stale}}(x_{\text{candidate}}) \le f_{\text{stale}}(x_{\text{source}}) \tag{14}$$

同时要求固定分类器的 Tripel 概率超过原始样本和仅做截尾对照至少 0.01。该阈值是操作性的非平凡变化标准，并非真实风格成功阈值。候选选择按模型概率进行，因此会适应诊断分类器；高概率不能作为优化之后仍独立的验证证据。未找到候选时保留原样并记失败，原样不算成功迁移。

扩大搜索后，11 个源样本都找到满足当前模型条件的候选，其中 9 个具有四项缺陷源字段实测，另 2 个缺少双乙酰值，只能相对插补值检查；Stale hops 对全部样本都是学习得到的代理。源样本中 2 个属于生成器留出集，其余为训练来源。增加搜索范围带来更多模型可行候选，但没有增加真实品评证据。

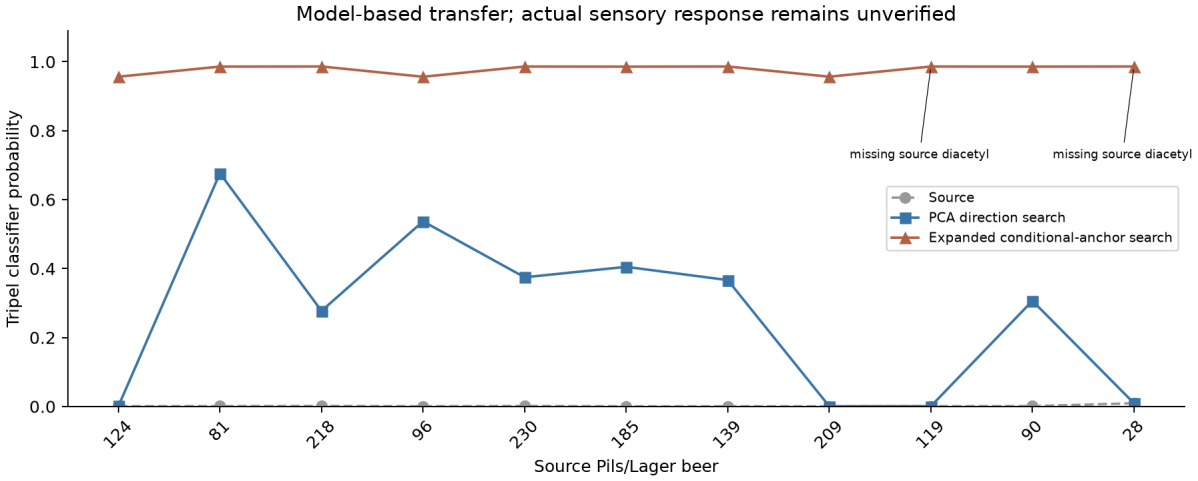


图6 扩展搜索与单一 PCA 方向搜索的内部分类概率比较 缺失源值另作标注

DMS 与其他缺陷的单位并不统一，部分尺度和 trans-2-nonenal 阈值也未确定。本文因此不声称全部绝对 OAV 阈值已通过。测量字段逐项不增加是较保守的模型条件，但若来源值有检测限替代、缺失或尺度歧义，仍需逐项补证。下一步应恢复基本成分的浓度和聚合公式，加入发酵过程与酿造可行性，再以盲评检验感官效应。

7 稳健性 可复现性与模型评价

7.1 已完成的稳健性检查

本流程分别保存了分层重复留出、训练折调参、额外随机缺失、网络阈值变化、bootstrap 网络重建、跨方法排名、留出置换、分级规则变化和生成划分变化。第一阶段与第二阶段分目录存储，保留方法变化前后的成绩和失败样本。23 项程序检查覆盖主键对齐、原件未改、预处理隔离、符号拉普拉斯性质、区间残差排序、留出角色、逐项缺陷和失败标记；这些检查证明实现满足指定性质，不证明全部科学假设成立。

7.2 优点与适用范围

流程的主要价值是把尺度审计、预测验证、关联证据和生成约束分开评估。简单参照使性能提升可比较，弱因素与失败案例保留使解释不过度确定，模型内约束也明确限定在可观测字段或代理。对类似小样本、高维、混合量纲的风味研究，这些步骤比单纯增加模型复杂度更有实际参考价值。

7.3 局限与改进方向

其一，原始逐人评分与绝对锚点缺失使真实 0—6 分不可恢复；分级规则高度分歧，不能把假设等级包装成真值。其二，噪声、检测限、品评差异和有限样本限制预测能力，且源数据预处理范围未完全明确。其三，Top-3 多数不稳定，反直觉项缺少因果证据；图约束参数与解释阈值也需要更系统敏感性。

其四，生成验证的稀有风格留出过少，分类器共享训练信息且会被迁移搜索适应；重复分割不能代替新数据。其五，聚合量公式、物理约束、缺陷阈值和感官实验未完成。其六，第二阶段已经基于第一阶段经验设计，缺少完全封存的最终外部测试。因此本文定位为可复核的参考研究，后续应以新增测量、品评锚点和独立实验补充关键证据。

8 结论与建议

在当前附件尺度上，化合物对感官画像具有一定预测信息：固定配置 GBR 的连续宏平均 MAE 为 0.3398，优于均值参照；但原始 0—6 分缺少可识别条件，不应声称已恢复。加入训练、校准和测试隔离的区间示例，可补充连续预测的不确定性表达，仍需遵守边际覆盖及交换性限制。

化合物网络可组织共变关系并提供正则化信息，但 150 条 Top-3 仅 11 条满足当前相对支持判据，说明稳定解释和化学机制是后续重点。生成比较显示局部凸组合在非复制与风格诊断之间有实用折中，复杂高斯模型尚未表现出全面优势。扩展搜索扩大了模型内可行迁移范围，却不能替代真实浓度阈值、酿造过程或品评验证。

后续研究优先顺序为：获取原始评分或参考酒锚点；复核尺度、检测限与异常；对关键因素开展浓度和文献核查；用封存的新样本验证生成与迁移；最后据实更新论文与 AI 使用记录。

参考文献

[1] Schreurs M, Piampongsant S, Roncoroni M, et al. Predicting and improving complex beer flavor through machine learning. Nature Communications, 15:2368, 2024. DOI:10.1038/s41467-024-46346-0.

[2] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12:2825-2830, 2011.

[3] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees. Machine Learning, 63:3-42, 2006. DOI:10.1007/s10994-006-6226-1.

[4] Friedman J H. Greedy function approximation: A gradient boosting machine. The Annals of Statistics, 29(5):1189-1232, 2001. DOI:10.1214/aos/1013203451.

[5] Lei J, G'Sell M, Rinaldo A, et al. Distribution-Free Predictive Inference for Regression. Journal of the American Statistical Association, 113(523):1094-1111, 2018. DOI:10.1080/01621459.2017.1307116.

[6] Scikit-learn developers. Permutation Importance with Multicollinear or Correlated Features. https://scikit-learn.org/stable/auto_examples/inspection/plot_permutation_importance_multicollinear.html，访问日期：2026-10-24.

[7] Vanbeneden N, Saison D, Delvaux F, Delvaux F R. Decrease of 4-vinylguaiacol during beer aging and formation of apocynol and vanillin in beer. Journal of Agricultural and Food Chemistry, 56(24):11983-11988, 2008. DOI:10.1021/jf8019453.

[8] OpenAI Codex，GPT-6 家族（精确可公开版本待核验），OpenAI，使用日期：2026-10-24.

AI 工具使用声明

本参考研究使用 OpenAI Codex 辅助进行资料检索、代码实现、数据审计、实验记录、图表和稿件编写[8]。正文所述计算为 AI 辅助代码的实际运行结果，不能据此声明核心工作已由参赛队员独立完成。队员后续应独立理解、验证、修改并记录实际贡献；采纳内容须按赛事要求在相应位置标注。模型家族信息可由会话核验，精确版本应按实际界面补充，不臆造版本号。重要交互与采纳修改记录见随附 AI 使用阶段记录，最终提交前须补全规定的 PDF 说明。

附录 复现与结果索引

第一阶段运行 run.py all，第二阶段运行 run_stage2.py，配置分别为 config.json 和 config_stage2.json。原始附件由使用者自行取得并经 source_manifest.csv 核对哈希。Python 与依赖版本锁定在 requirements-lock.txt；生成论文的脚本位于 scripts/，原始数据未随公开仓库分发。

材料	路径与内容
数据证据	outputs/stage2/audit/：字典、原件哈希、尺度和模板检查
第一问	outputs/stage2/q1/：连续误差、GBR 留出预测、分级敏感性和区间覆盖
第二问	outputs/stage2/q2/：完整置换贡献与 150 条候选证据；原始网络见 stage1/q2
第三问	outputs/stage2/q3/：生成对照、局部样本、画像、迁移与缺陷检查
研究源代码	src/、run.py、run_stage2.py；算法与完整运行代码随支撑包提供
入门教程	docs/从数据到论文的解题教程.md；按数据、模型、验证与论文顺序阅读

本稿未逐页排入全部源代码，也未填写队号、承诺书和队员独立贡献。若转为正式参赛作品，应依据官方要求把全部实际使用源程序纳入附录，并完成匿名、页数、引用与 AI 披露检查。参考稿中的条件、失败结果和未证实事项不得在修改时无依据删除。